Empreendedorismo Feminino no Brasil

Equipe: Kauã Kley, Luan Victor e Beatriz Costa

1. Levantamento de Parâmetros e Tipagem de Dados

Identificação da Fonte

- **Fonte:** microdados da PNAD Contínua trimestral, do IBGE (Pesquisa Nacional por Amostra de Domicílios Contínua).
- **Formato de origem:** arquivo TXT de largura fixa (fixed-width), compactado em `.zip`, baixado do FTP do IBGE. Não é CSV, JSON, Parquet nem API. Cada linha é uma pessoa, e cada variável ocupa uma faixa fixa de caracteres, sem separador.
- **Arquivos de apoio:**
    1. `input_PNADC_trimestral.txt`: layout em formato SAS, com posição inicial, tipo e tamanho de cada variável.
    2. `dicionario_PNADC_microdados_trimestral.xls`: significado das variáveis e dos códigos das categorias.
    3. `Variaveis_PNADC_Trimestral.xls`: disponibilidade de cada variável por trimestre.
    4. Definições das variáveis derivadas (prefixo `VD`), em PDF.
- **Dados obtidos:** 1º e 2º trimestres de 2026 (`PNADC_012026.txt` e `PNADC_022026.txt`), com cerca de 4.000 caracteres por linha e mais de 500 mil linhas por trimestre.
- **Recorte de análise:** empreendedorismo feminino no Brasil, com indicador para pegar só a Bahia e só Salvador também
- **Camada de ingestão:**
    1. Leitura do TXT com o layout do `input`.
    2. Conversão de tipos.
    3. Gravação em Parquet (camada intermediária).
    4. Carga no PostgreSQL (Aiven).

Cada linha do TXT tem muitas colunas de pesos replicados, que ocupam a maior parte do espaço e não são necessárias para a análise.

Estratégia de Otimização de Volume (limite de 1 GB no Aiven)

Cada trimestre tem centenas de milhares de linhas com cerca de 4.000 caracteres. Como isso não caberia no limite, o volume é reduzido antes da carga, na etapa de transformação do ETL, com estas medidas:

1. **Filtro geográfico:** Apesar de pegarmos o brasil inteiro, também pegaremos registrossó da Bahia (`UF = 29`), identificados já na leitura pelas posições 6-7 da linha, sem processar

as demais UFs. Salvador é identificada pela variável `Capital` e mantida como coluna indicadora.
2. **Seleção de colunas:** de centenas de variáveis, ficam cerca de 15 a 20, ligadas ao tema (sexo, raça, idade, escolaridade, posição na ocupação, formalização, porte, setor, renda, peso e identificadores do desenho amostral). Os pesos replicados são descartados.
3. **Filtro de universo:** apenas pessoas ocupadas, com dados de posição na ocupação (empregadora, conta própria, empregada etc.), o que permite comparar empreendedoras com o restante da força de trabalho.
4. **Leitura em fluxo (streaming):** o arquivo é lido linha a linha ou em blocos (`chunksize`), sem carregar o TXT inteiro na memória.
5. **Formato colunar intermediário:** o Parquet compacta melhor que o TXT e serve de checkpoint antes da carga.
6. **Tipos compactos no banco:** `SMALLINT` para códigos e `NUMERIC` para valores, em vez de texto.
7. **Monitoramento:** conferência do tamanho do banco após cada carga.

Estimativa (a confirmar após a primeira carga): a Bahia responde por uma fração pequena da amostra nacional. Depois dos filtros, cada trimestre deve ficar na ordem de dezenas de milhares de linhas com cerca de 20 colunas, ou seja, poucos MB. Mesmo com vários trimestres, o volume deve ficar bem abaixo de 1 GB.

Ação Requerida: Filtros, Amostragem ou Agregações

Técnica	Será aplicada?	Justificativa
Filtro de recorte temporal	**Sim**	Inicialmente 1º e 2º tri/2026. Se houver folga no limite, incluem-se trimestres anteriores para ampliar a série.
Filtro geográfico	**Sim**	Bahia (`UF = 29`), com indicador de Salvador.
Filtro de universo	**Sim**	Apenas pessoas ocupadas.
Amostragem estatística	**Não**	A PNAD já é uma amostra complexa, com pesos. Amostrar de novo distorceria as estimativas. Reduzimos o volume por filtragem, não por sorteio.
Agregação prévia	**Parcial**	Além da tabela detalhada (nível pessoa), gera-se uma tabela agregada (trimestre × sexo × raça × posição na ocupação × formalização, com soma dos pesos e renda média ponderada) para consultas rápidas. Os dados detalhados são mantidos, porque a agregação prévia impede novos cruzamentos.

Mapeamento de Variedade e Tipagem

Na PNAD, os valores monetários já vêm como número puro, sem "R$", vírgula ou ponto de milhar, e os pesos trazem ponto decimal explícito. A conversão principal é, portanto, de texto posicional

para tipos numéricos, com tratamento de valores vazios. Campos vazios significam "não se aplica" (pessoa fora do universo da pergunta) e viram `NULL`, não erro.

Coluna	Descrição	Tipo na origem	Tipo destino (PostgreSQL)	Transformação
`Ano`	Ano de referência	Texto (4 caracteres)	`SMALLINT`	Conversão numérica
`Trimestre`	Trimestre (1 a 4)	Texto (1 caractere)	`SMALLINT`	Conversão numérica
`UF`	Unidade da Federação (29 = Bahia)	Texto (2 caracteres)	`SMALLINT`	Conversão numérica e filtro
`Capital`	Município da capital	Texto (2 caracteres, vazio se não aplicável)	`SMALLINT` (aceita `NULL`)	Vazio vira `NULL`; deriva o indicador `is_salvador` (`BOOLEAN`)
`UPA`	Unidade Primária de Amostragem	Texto (9 caracteres)	`VARCHAR(9)`	Mantida como texto (identificador)
`Estrato`	Estrato amostral	Texto (7 caracteres)	`VARCHAR(7)`	Mantida como texto (identificador)
`V1028`	Peso amostral com calibração	Numérico (15 posições, ponto explícito)	`NUMERIC(15,8)`	Conversão numérica
`V2007`	Sexo	Texto (código)	`SMALLINT` + rótulo	Conversão e mapeamento para categorias
`V2009`	Idade	Texto (3 caracteres)	`SMALLINT`	Conversão numérica
`V2010`	Cor ou raça	Texto (código)	`SMALLINT` + rótulo	Conversão e mapeamento para categorias
`VD3004`	Nível de instrução	Texto (código)	`SMALLINT` + rótulo	Conversão e mapeamento
`VD4002`	Condição de ocupação	Texto (código)	`SMALLINT` + rótulo	Conversão; usada no filtro de ocupados
`VD4007` / `VD4009`	Posição na ocupação	Texto (código)	`SMALLINT` + rótulo	Conversão e mapeamento; define a empreendedora

	(empregadora, conta própria etc.)			
`V4019`	Negócio registrado no CNPJ	Texto (código)	`SMALLINT` (aceita `NULL`)	Não aplicável vira `NULL`; deriva o indicador `formalizada` (`BOOLEAN`)
`V4018`	Nº de pessoas no negócio	Texto (código de faixa)	`SMALLINT` (aceita `NULL`)	Conversão e rótulo de faixa
`VD4010`	Grupamento de atividade	Texto (código)	`SMALLINT` + rótulo	Conversão e mapeamento
`VD4016`	Rendimento habitual do trabalho principal	Numérico em texto	`NUMERIC(12,2)` (aceita `NULL`)	Conversão numérica; vazio vira `NULL`

Observações metodológicas

- **Rendimento:** usaremos `VD4016` (trabalho principal) e não `VD4019` (todos os trabalhos), para ficar coerente com a posição na ocupação, que também se refere ao trabalho principal.
- **Variáveis derivadas:** as variáveis `VD` são calculadas pelo IBGE. As definições estão nos PDFs de variáveis derivadas e serão citadas no trabalho.
- **Validade por período:** algumas variáveis só existem em certos trimestres (por exemplo, `VD4032` e `VD4033` só até o 3º tri/2015). Por isso, conferimos na coluna "Período" do dicionário e no `Variaveis_PNADC_Trimestral.xls` se cada variável existe em 2026.
- **Rótulos das categorias:** os códigos de `V2007`, `V2010`, `VD4007`, `VD4009` e `V4019` serão mapeados a partir do dicionário `.xls`. Esses rótulos ainda precisam ser conferidos nele (por exemplo, o código de Salvador em `Capital`) antes de você fechar a entrega.